Basi di dati

Marini Mattia

1^o semestre 2^o anno

Indice

1 Introduzione

Per immagazzinare dati abbiamo bisogno di:

- Base di dati raccolta organizzata di informazioni
- Database Managment System o DBMS: pacchetto software per gestire basi di dati

L'insieme di base di dati e DBMS è detto database system

Un DBMS deve fornire come minimo:

- Data Definition Language (DDL) ossia un linguaggio che permetta di definire la struttura dei dati
- Data Manipulationn Language (DML) o quey language, che permetta di modificare ed estrarre i dati
- Garantire robustezza dei dati, rendendo possibile il recupero in caso di corruzione
- Gestire problemi di concorrenza:
  - Evitare interazioni indesiderate tra utenti *isolation*
  - Evitare modifiche incomplete dei dati *atomicity*

1.0.0 Vantaggio database

Utilizzare un database comporta molti vantaggi. Uno dei più importanti è che permette la separazione tra programmi e dati

Devo modificare lo schema fisico secondo il quale salvo i dati

Database	Salvataggio su file
◦ Modifico database, ma modalità logiche secondo le quali accedo e modifico dati rimangono le stesse ◦ Applicazione non deve essere modificata	◦ La struttura del file è memorizzata nel programma ◦ Cambio struttura file ◦ Applicazione deve essere modificata

Dunque il salvataggio su file rende manutenzione difficile e costosa

1.0.0 Livelli di astrazione

- Schema fisico: fornisce dettagli su come i dati sono salvati fisicamente nella memoria
- Schema concettuale: modello di alto livello che rappresenta i dati nei termiini del modello del DBMS
- Schema esterno: permette di creare una o più vistte per interfacciarsi con il database

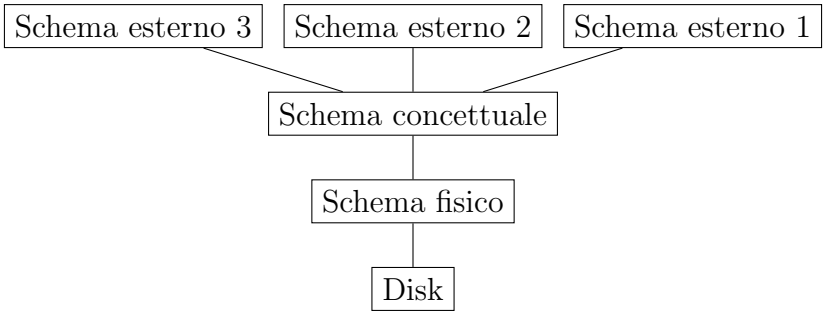

1.0.0 Attori sulla scena

- Database administrator: monitora utilizzo DB, regola accesso, acquista risose hardware e monitora efficienza
- Database designer: crea il design del DB, definendone lo schema e i vincoli sulle transaioni

Utenti finali (utilizzatori database):

- Casual: "accedono da esperti", ma occasionalmente, quando necessario
- Naive
  - Utilizzano funzioni predefinite
  - Es. cassiedi di banca, impiegati, utenti di siti web...
- Sophisticated: business analysts, data scientists, ingegneri. Utilizzano software molto vicini a quello della base di dati
- Stand-alone: utenti che si creano una base di dati "per conto loro", ad esempio un commercialista che si crea un database con i dati dei suoi clienti

2 Progettazione di una base di dati

Le fasi della progettazione di una base di dati sono le seguenti:

- Fasi principali
  - Analisi dei requisiti
  - Progettazione concettuale
  - Progettazione logica
- Fasi seconda parte
  - Raffinamento dello schema logico (normalizzazione)
  - Progettazione del livello fisico
  - Progettazione applicativa e sicurezza

2.1 Concetti base modellazione logica

2.1.0 Entità

- Un'entità è un oggetto singolo del mondo reale. Ad esempio Mario
- Un entity set è un insieme di entità, quindi ad esempio il gruppo di amici Mario, Paolo e Nicola
- Un entity type è il tipo generico di entità, ad esempio Persona

Un'entity è rappresentata tramite un quadrato nei diagrammi:

2.1.0 Attributi

- Un attribute è una proprietà usata per descrivere un'entity. Ad esempio, mario avrà codice fiscale, numero telefono...
- Un value set o data type è la variabile che contiene il valore dell'attributo

Gli attributi possono essere semplici, composti e multi valore. Noi useremo quelli semplici e basta. Possiamo ricreare gli altri tramite diversi workarround Un'entity è rappresentata tramite un ovale nei diagrammi:

L'attributo viene collegato all'entity type al quale fa riferimento

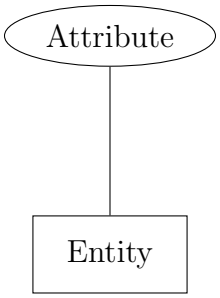

2.1.0 Attributo chiave

Un attributo chiave è un attributo che identifica in maniera univoca l'entità alla quale fa riferimento. Ad esempio, l'isbn di un libro. La chiave primaria va sempre sottolineata:

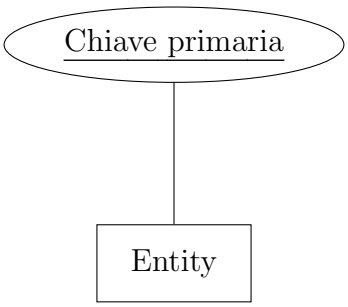

Una chiave può essere inoltre

- Composta, ossia formata da più attributi. Ad esempio, nome e matricola
- Multipla, ossia vi sono più chiavi candidate, ad esempio la targa e il numero di telaio di un'automobile. Va sempre comunque indicata la chiave principale

2.1.0 Relazioni

Una relazione è un'associazione tra due o più entity

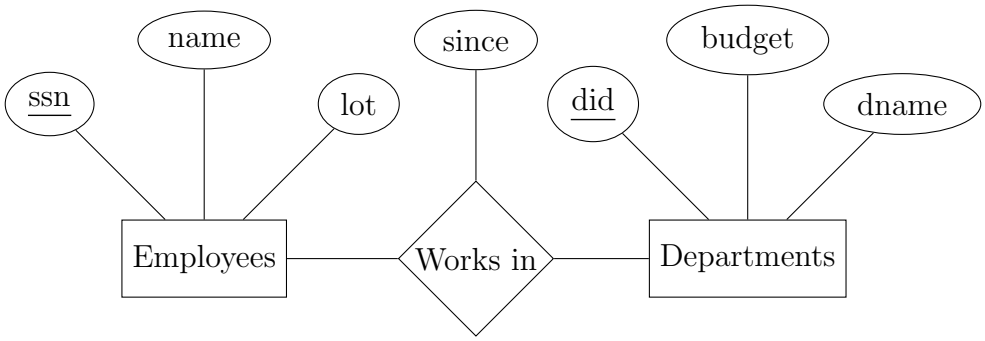

Una relazione può essere anche a 3 (uwu)

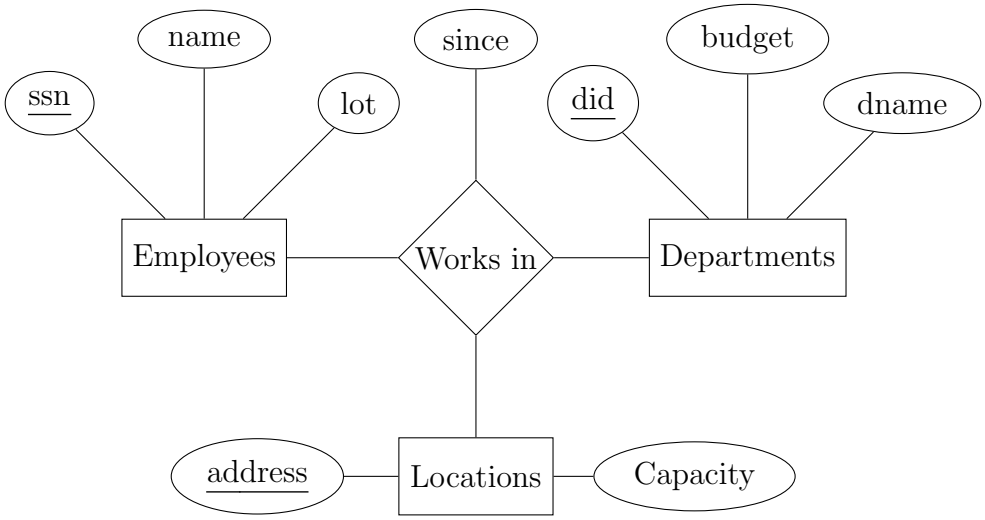

2.2 Vicoli di relazione

Spesso abbiamo bisogno di specificare qualche vincolo riguardo ad una relationship tra due entity

2.2.0 Vincolo di chiave

Si rappresenta con una freccia:

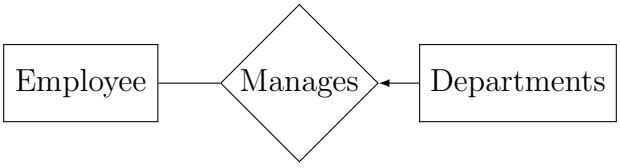

In questo caso significa che ogni dipartimento può avere **al più** un manager

2.2.0 Vincolo di partecipazione

Si rappresenta con una linea grossa:

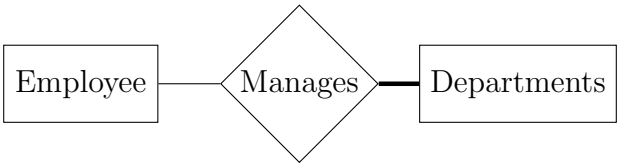

In questo caso significa che ogni dipartimento deve avere **almeno** un manager

I vincoli di chiave e di partecipazione possono essere uniti, come segue:

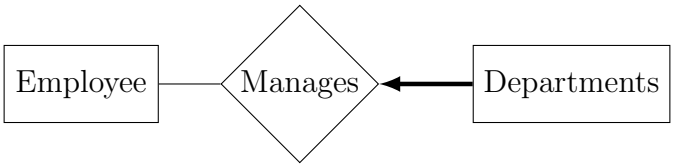

In questo caso significa che ogni dipartimento ha **esattamente** uno e uno solo manager

2.2.0 Esempio completo

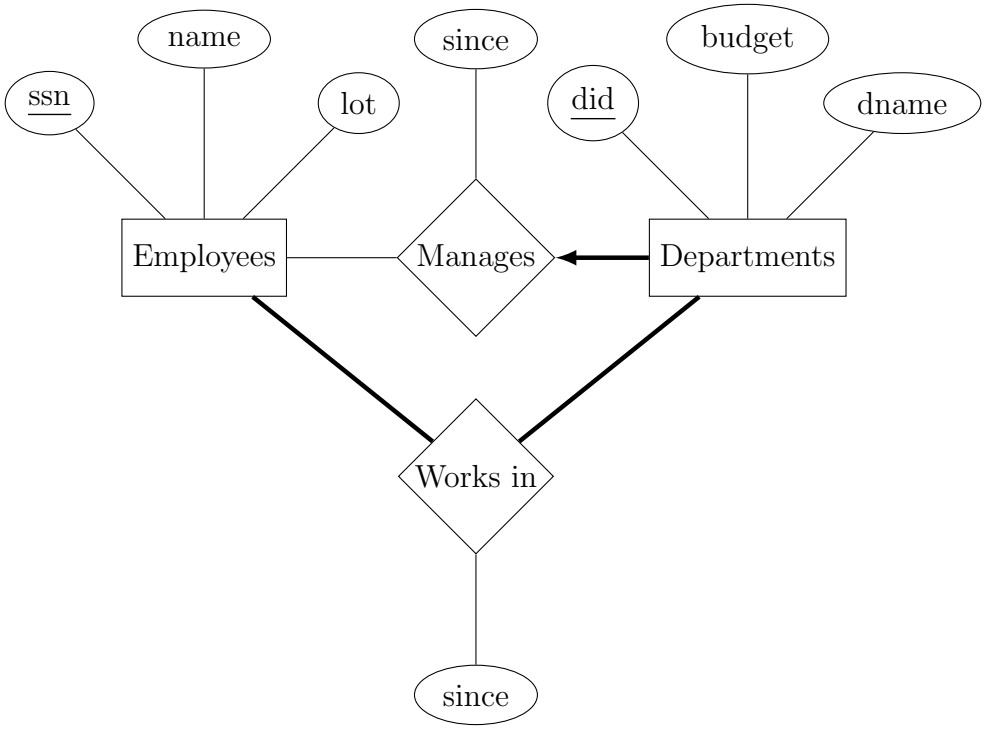

2.2.0 Notazione (min, max)

Una notazione alternativa per esprimere dei vincoli sul numero di entity coinvolte nella relazione è utilizzare un disegno come segue:

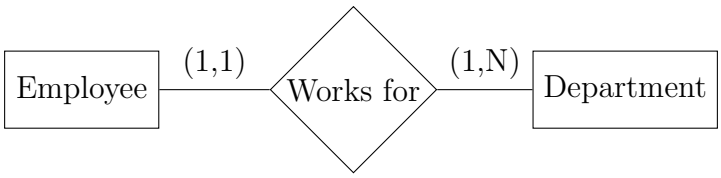

Nel primo caso si legge: un Employee può essere manager di 0 o 1 department. Un department può essere gestito da un solo manager

2.2.0 Gerarchie di classi

Come usiamo la generalizzazioe all'interno dei class diagrams, possiamo utilizzarla nei diagrammi er

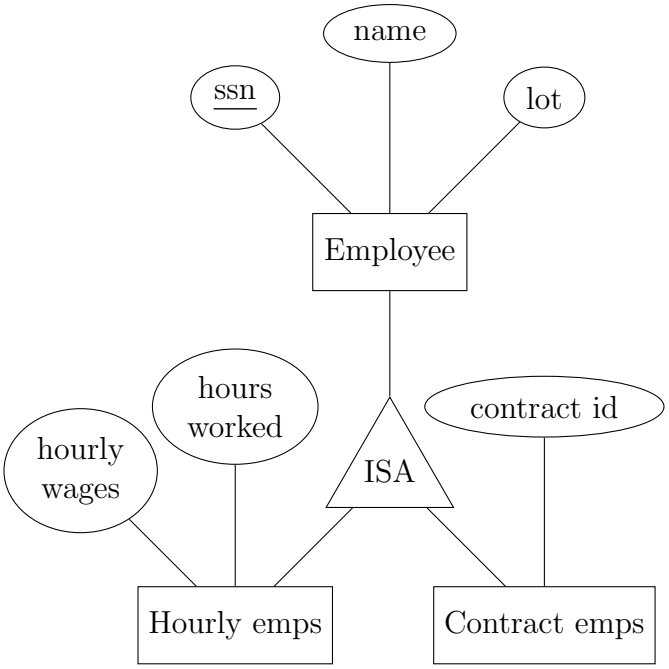

In questo casi si dice che:

- `Hourly emps` e `Contract emps` sono generalizzati in `Employee`
- `Employee` si specializza con `Contract emps` e `Hourly emps`

Inoltre possiamo rappresentare i seguenti concetti di overlap e copertura secondo i seguenti schemini grafici

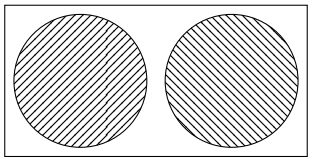

No overlap, copertura parziale

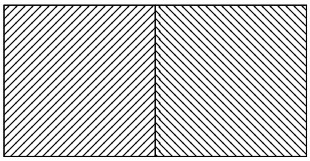

No overlap, copertura totale

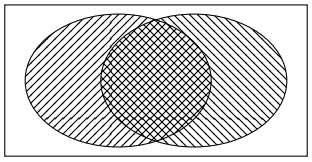

Overlap, copertura parziale

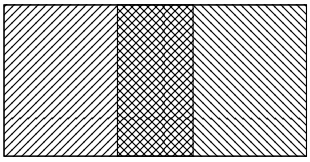

Overlap, copertura totale

2.2.0 Aggregazione

3 Riassuntone

3.1 Termini

- Superchiave: un insieme di attributi che identifica univocamente una tupla
- Superchiave minimale: superchiave che se si toglie uno qualsiasi degli attributi non è più chiave
- Chiavi candidate: tutte le superchiavi minimali di una relazione
- Attributo primot: attributo che appartiene almeno ad una chiave candidata
- Attributo non primot: attributo che non appartiene a nessuna chiave candidata
- Schema (scheme): insieme di tabelle e vincoli di integrità di un db

3.2 Vincoli

- Dominio: il tipo inserito in una colonna deve rispettare il formato della colonna stessa:
  - Data type *string, int,...*
  - Range (*int in range 0-120*)
  - Format (*mail, contains "@"*)
  - Enum values (*value can be either a,b,c,...*)
  - Null constrait (*Item cannot be null*)
- Chiave: deve esistere una chiave per ogni relazione
- Integrità delle entità: nessun valore della chiave primaria può essere null
- Integrità referenziale: una foreign key non può far riferimento ad una tupla non presente nella relazione referenziata
- Vincoli di integrità semantica: vincoli che non possono essere espressi dal dbms stesso (*es, tutti gli impiegati non possono lavorare più di 46 ore a settimana*)

3.2.0 Violazione dei vincoli

- Insert: viola tutti:
  - Dominio (valore con tipo sbagliato)
  - Integrità entità (chiave null)
  - Integrità referenziale (Fk non esiste)
  - Integrità semantica
- Delete

- Integrità referenziale (toglie valore referenziato)
- Update: viola tutti:
  - E' come delete + insert

3.2.0 Mantenere integrità

- Restrict: impedisce operazione
- Cascade: rimuove tuple che referenziano tupla eliminata
- Set null/default: setta la chiave referenziante a nulla/default value

3.3 Mapping

- Vincolo di chiave (E_1, E_2, vincolo su E_2)
  - Opzione 1: $FK(E_1, E_2), PK(E_2)$
  - Opzione 2: aggiungo colonna a E_2 che referenzia $PK(E_1)$
- Vincolo di partecipazione totale (E_1, E_2, vincolo su E_2): non può essere rappresentato completamente, ma solo in parte
  - Aggiungo *not null* sulla $FK(E_1)$ in E_2
- Weak entities (E_1, E_2, E_2 è weak)
  - $FK(E_2)$ è *not null* (attributo non esiste senza istanza padrone)
  - ON DELETE CASCADE per eliminare weak instance quando viene eliminata estanza padrone
- Gerarchie IS-A (E, C_1, C_2):
  - Opzione 1:
    - $PK(E) =$ ssn $PK(C_1) = FK(C_1) =$ ssn e estessa cosa per C_2
    - ON DELETE CASCADE: se elimino superclasse elimino anche classe child corrispondente
  - Opzione 2 (se ce copertura totale): elimino classe padre
- Aggregazioni: Relazione esterna ha attributi della relazione interna e la chiave di ciò a cui è collegata. Si può semplificare se
  - Relazione esterna non ha attributi
  - Aggregazione ha vincolo di partecipazione totale su relazione esterna

3.4 Algebra relazionale

- σ: select
- π : project
- ρ: rename
- Divisione: $A\,(x, y)\,/B\,(y)$
  - Raggruppo per colonne x di A
  - Metto in tabella risultato gli x che hanno tutti gli y di A

$$A/B = \{x \text{ t.c. } \exists\,\langle x, y\rangle\,\forall y \in B\}$$

3.5 Normalizzazione

- **Prima forma normale**:
  - No attributi multivalore
  - No tuple duplicate (esiste chiave)
- **Seconda forma normale**: no dipendenze parziali
  - Controlla che tutti gli attributi non primi non dipenda parzialmente da alcuna chiave candidata

  Terza forma normale: no dipendenze transitive. Per ogni dipendenza funzionale, $X \to Y$

  Ogni freccia entrante in un attributo non primo deve dipendere da una chiave candidata
  - X è superchiave
  - Y è primo
- **Forma di Boyce Codd**
  - Per ogni df $X \to Y$, X deve essere una superchiave

3.6 Livello fisico

3.6.0 Terminologia

- P: dimensione della pagina
- S : dimensione del file
- t_R dimensione di una tupla di una tabella R
- P_R: numero di pagine che contengono tuple di R
- $|R.A|$: numero di valori diversi per l'attributo A

- $|R|$: numero di tuple di R
- $|R_{c==c}|$: numero di tuple per le quali è soddisfatta la condizione c == c
- $f = \frac{1}{|R.A|}$: selectivity factor

3.6.0 Heap list

- Scan
$$P_R$$
- Equality search
$$P_R$$
- Insert
$$2$$
leggo ultima pagina in $\frac{S}{P} - 1$ e eventualmente ne aggiungo una nuova
- Delete
$$P_R + |R_{c=c}| \quad \text{dove } |R_{c=c}| \approx \frac{|R|}{|R.A|}$$

3.6.0 Sorted file

- Scan:
$$P_R$$
- Equality search o ricerca per intervallo:
$$\log_2(P_R) + \left\lceil \frac{|R_{c=c}|}{\frac{P}{t_R}} \right\rceil$$
- Delete:
$$\log_2(P_R) + 2 \cdot \left\lceil \frac{|R_{c=c}|}{\frac{P}{t_R}} \right\rceil$$
il $\cdot 2$ è dato dal fatto che le pagine contenenti le tuple vanno prima lette e poi eliminate
- Insert
$$\log_2(P_R) + 1$$
Se non c'è spazio ho bisogno di spostare tutte le P_R tuple nel caso peggiore

3.6.0 B+ tree

Costo lookup:

$$\log_B (R.A)$$

Equality search unclustered (nel caso peggiore ogni tupla sta in una pagina diversa):

$$\log_B (R.A) + R_{a=a}$$

Equality search clustered (tuple sono contigue quindi complessità diminuisce):

$$\log_B (R.A) + \left\lceil \frac{|R_{a=a}|}{\frac{P}{t_r}} \right\rceil$$

Insert:

$$\log_B (R.A) + 2$$

3.6.0 Hash table

Costo lookup:

$$L_h \approx 1.2$$

Costo insert:

$$L_h + 2$$

3.7 Joins

3.7.0 Nested Loop Join

$$P_R \cdot (P_S + 1)$$

3.7.0 Sort Merge Join

Costo se tuple già ordinate:

$$P_R + P_S$$

Costo ordinamento tuple:

$$2 \cdot P_R \cdot \left(\left\lceil \log_{b-1} \left\lceil \frac{P_R}{B} \right\rceil \right\rceil + 1 \right)$$

3.7.0 Hash join

Costo se tuple già in bucket:

$$P_R + P_S$$

Costo inserimento in bucket:

$$P_R + 2 \cdot |R|$$

3.7.0 Indexed Nested Loop Join

$$P_R + |R| \cdot \text{ CostoEqualitySearch}$$